

Восстановление нейтральных линий магнитного поля Солнца методами машинного обучения

Студент: Киселюс Вацловас

Научный руководитель: Илларионов Егор Александрович

МГУ им. М. В. Ломоносова
Механико-математический факультет
Кафедра теории вероятностей

Москва, 2023

План презентации

- 1 Введение
- 2 Цель работы
- 3 Постановка задачи
- 4 Основные этапы работы
- 5 Математический аппарат
- 6 Что такое полносвязная нейронная сеть?
- 7 Ключевые идеи
- 8 Текущие результаты
- 9 Имеющиеся проблемы и предполагаемые способы их решения
- 10 Список литературы

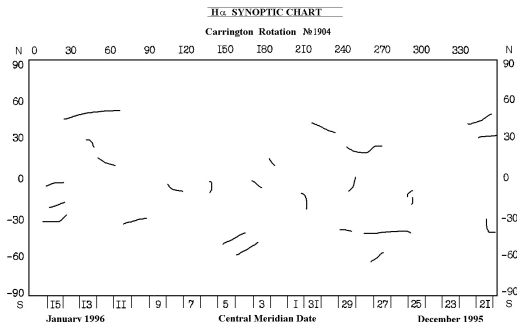


На Солнце постоянно происходят изменения, которые мы наблюдаем в виде солнечных пятен, корональных дыр, протуберанцев (см. рис.) и ряда других активных областей. Согласно сегодняшним представлениям, причиной образования

активных областей являются магнитные поля Солнца.

Предполагается, что протуберанцы (волокна) появляются вдоль нейтральных линий¹ магнитного поля Солнца.

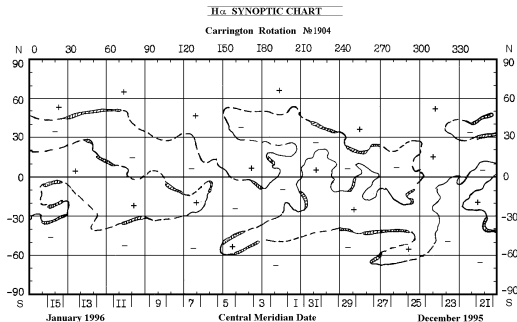
Рассмотрим данные о волокнах, полученные за полный оборот Солнца вокруг своей оси. Как видно из рисунка слева, волокна образуются лишь на отдельных участках нейтральной линии, поэтому возникает вопрос: а можно ли восстановить нейтральные линии магнитного поля?



¹т.е. на границе участков поверхности Солнца, знак магнитного поля которых отличается.

Синоптические карты

Действительно, астрономы пытаются восстановить нейтральные линии и составляют *синоптические карты*.



Рассмотрим одну из них. Как видно, волокна соединены пунктирной линией, однако это сделано человеком вручную. К тому же, разные наблюдатели могут получить разные карты, поскольку каждый может по-своему достроить нейтральные линии.

Имеющиеся на сегодняшний день алгоритмы не показывают ожидаемого результата. Поэтому целью данной работы является разработка универсального алгоритма получения синоптических карт по скопившимся за многие десятилетия данным о солнечных волокнах и обработка этого большого объема данных. К тому же, хочется иметь возможность вероятностного вывода, т.е. чтобы алгоритм помимо достраивания нейтральных линий дополнительно сообщал об уверенности своего решения.

Постановка задачи

Входными данными является информация о волокнах. Она представлена в виде матрицы $(a_{ij})_{m \times n}$, где m и n – размеры синоптической карты.

$$a_{ij} = \begin{cases} 0 & \text{если пиксель с координатами } (i, j) \text{ соответствует волокну} \\ 1 & \text{иначе} \end{cases}$$

На выходе требуется получить матрицу $(b_{ij})_{m \times n}$

$$b_{ij} = \begin{cases} 1 & \text{если знак магнитного поля положительный} \\ -1 & \text{если знак магнитного поля отрицательный} \\ 0 & \text{иначе} \end{cases}$$

Основные этапы работы

- Изучение имеющихся данных
- Выбор подхода к решению задачи
- Подготовка данных
- Построение модели
- Эксперименты

Суть подхода заключается в построении нейронной сети, которая бы реализовывала функцию

$$f(x, y, z) : S^2 \subset \mathbb{R}^3 \rightarrow [-1, 1]$$

Архитектура модели была выбрана эмпирически – это полносвязная нейронная сеть с тремя входами (координаты на сфере) и с одним выходом (число от -1 до 1). Функция потерь, необходимая для обучения алгоритма, конструировалась из следующих соображений:

- функция f должна быть простой (для этого применяется L_2 -регуляризация весов);
- линия уровня 0 этой функции есть искомая нейтральная линия;
- при переходе через границу (волокно) функция меняет знак;
- $\int_{S^2} f dV = 0$ (магнитное поле Солнца нейтрально);
- нам известен знак поля на северном и южном полюсах.

Что такое полносвязная нейронная сеть?

С помощью нейронной сети можно конструировать сколь угодно сложные функции, она является универсальным аппроксиматором. Полносвязная нейронная сеть состоит из входного, скрытых и выходного слоев, каждый из которых состоит из нейронов. Каждый нейрон, за исключением входных, получает на вход **взвешенные** сигналы со всех нейронов предыдущего слоя, суммирует их и пропускает через функцию активации. Полученное значение передается нейронам на следующем слое. Цель обучения – подобрать **веса** каждого слоя так, чтобы минимизировался некий функционал, называемый функцией потерь (loss function).

Архитектура модели


Функцией активации для последнего слоя был выбран

$$\tanh x = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Область значений этой функции есть $[-1, 1]$. После всех остальных слоев применяется функция

$$ELU(x) = \begin{cases} x & x \geq 0 \\ e^x - 1 & x < 0 \end{cases}$$



Модель имеет 3 скрытых слоя, в которых по 6, 12 и 24 нейронов.



Итак, исходя из соображений на слайде 9, предлагается использовать следующую функцию потерь:



$$\mathcal{L}(f) = w_1 \left| \int_{S^2} f dV \right| + w_2 \int_{\mathcal{F}} f^2 dV + \left(1 - w_3 \int_{S^2 \setminus \mathcal{F}} |f| dV \right) + \gamma$$

Здесь w_i – нормировочные веса, подобранные так, чтобы любое слагаемое в \mathcal{L} лежало в пределах от 0 до 1; \mathcal{F} – область, соответствующая наблюдаемым волокнам; член γ отвечает за ориентацию магнитного поля.





Эксперименты демонстрируют, что модель показывает лучшие результаты, если сначала обучить ее на более крупномасштабной версии (левый рисунок) изображения, а затем дообучить модель на оригинальном входе (на правом рисунке).

Ключевые идеи



Данный пример иллюстрирует состоятельность подхода: в виду непрерывности конструируемой функции $f(x, y, z)$ модель достраивает нейтральную линию так, как интуитивно предположил бы и человек.

Текущие результаты



На сегодняшний день имеющаяся модель справляется с раскраской изображения, когда граница задана полностью, либо же *частично*. Однако, используя только входные данные о волокнах, модель пока что не способна показать ожидаемый результат. В этом направлении и ведется текущая работа.

Имеющиеся проблемы

Эксперименты показали, что при нескольких независимых запусках процесса обучения модели на одних и тех же входных данных результаты могут существенно отличаться. Это ожидаемый эффект, поскольку задача может иметь несколько решений (ill-posed problem)

Для решения этой проблемы может помочь использование соседних карт. Действительно, идущие друг за другом карты имеют похожую структуру, что согласуется со здравым смыслом. Поэтому, например, можно обучать модель не на одной, а сразу на нескольких картах, расположенных в виде концентрических сфер, цилиндров или склеенных по спирали.

В разработке также находится идея с адаптивными весами w_i в loss-функции (то бишь сделать их не гиперпараметрами, а обучаемыми).

- [1] McIntosh, P. S. 1972, Reviews of Geophysics and Space Physics, 10, 837. doi:10.1029/RG010i003p00837
- [2] Ipson, S. S., Zharkova, V. V., Zharkov, S. et al. Automated Technique For Comparison Of Magnetic Field Inversion Lines With Filament Skeletons From The Solar Feature Catalogue. Sol Phys 228, 399–421 (2005). <https://doi.org/10.1007/s11207-005-6878-2>
- [3] Wang, Jie. “An Intuitive Tutorial to Gaussian Processes Regression.” ArXiv abs/2009.10862 (2020): n. pag.
- [4] McClenny, Levi & Braga-Neto, Ulisses. (2020). Self-Adaptive Physics-Informed Neural Networks using a Soft Attention Mechanism.